영화 리뷰 감성 분석 대시보드 프로젝트

> **목표**: NSMC(네이버 영화 리뷰) 데이터를 HuggingFace 모델로 감성 분류하고, 분류 결과를 **특성 엔지니어링**으로 원본 데이터에 추가한 뒤, Streamlit 대시보드로 인사이트를 시각화한다.

> 🗀 소스 파일: `source/5_week/movie_dashboard/`

---

1. 프로젝트 개요

항목	내용
주제	한국어 영화 리뷰 감성 분석 대시보드
데이터	NSMC (Naver Sentiment Movie Corpus, 네이버 영화 리뷰 20만건)
모델	WhitePeak/bert-base-cased-Korean-sentiment (정확도 92%)
기능	KPI 요약, 감성 분포, 키워드 분석, 모델 성능 평가, 데이터 조회
구조	멀티페이지 (홈, 모델 분석, 데이터 조회)
패턴	4주차 따릉이 대시보드와 동일한 구조

4주차 따릉이 vs 5주차 영화 리뷰 비교

비교 항목	따릉이 대시보드	영화 리뷰 대시보드
데이터 소스	서울 열린데이터 CSV	HuggingFace datasets (NSMC)
데이터 유형	수치 데이터 (대여건수, 이용시간)	텍스트 데이터 (리뷰 내용)
분석 방법	집계/통계 (groupby, sum, mean)	AI 모델 추론 (감성 분류)
특성 엔지니어링	반납건수 추정, 이용시간 평균 변환	감성 예측, 신뢰도, 정답 여부 추가
시각화	추이 차트, TOP5, 비중	혼동행렬, 신뢰도 분포, 키워드

3교시 앱과의 차이

비교 항목	3교시 감성 분석 앱	이 프로젝트
분석 대상	사용자가 입력한 **1건**	NSMC 데이터 **2,000건**
분석 시점	사용자가 버튼을 눌렀을 때 실시간	미리 대량 분석 후 결과 탐색
목적	"이 문장이 긍정인가 부정인가?"	"데이터 전체의 패턴과 인사이트는?"
핵심 기능	실시간 추론	특성 엔지니어링 + 성능 평가 + 시각화

---

2. NSMC 데이터셋 소개

NSMC (Naver Sentiment Movie Corpus)는 네이버 영화 리뷰에서 수집한 한국어 감성 분석 벤치마크 데이터셋입니다.

항목	내용
전체 크기	200,000건 (훈련 150,000 + 테스트 50,000)
컬럼	`id` (리뷰 ID), `document` (리뷰 텍스트), `label` (0=부정, 1=긍정)
라이선스	CC0 1.0 (자유 사용 가능)
출처	HuggingFace: e9t/nsmc

샘플 데이터:

```
| id        | document                          | label |
|----------|-----------------------------------|-------|
| 9976970  | 아 더빙.. 진짜 짜증나네요 목소리     | 0     |
| 3819312  | 흠...포스터보고 초기 기대를 했지만... | 0     |
| 10265843 | 너무재밌am ㅋㅋㅋ 감동 ㅋ             | 1     |
```

---

3. 프로젝트 구조

```
movie_dashboard/
├── app.py                      # 멀티페이지 진입점 (st.navigation)
├── .streamlit/config.toml      # 다크 테마 설정
├── pages/
│   ├── 1_home.py               # 대시보드 홈 (KPI + 감성 분포 + 키워드)
│   ├── 2_analysis.py           # 모델 성능 분석 (혼동행렬 + 신뢰도 + 오분류)
│   └── 3_data.py               # 데이터 조회 (특성 엔지니어링 결과 + 원본)
├── utils/
│   └── data_loader.py          # 데이터 로딩 + 감성 추론 + 특성 엔지니어링
└── data/                       # 분석 결과 CSV 캐시 (첫 실행 시 자동 생성)
    └── nsmc_analyzed.csv
```

---

4. 핵심 개념: 특성 엔지니어링 (Feature Engineering)

이 프로젝트의 핵심은 **특성 엔지니어링**입니다. 원본 데이터에 AI 모델의 분석 결과를 새로운 컬럼으로 추가하여 데이터의 분석 가치를 높입니다.

원본 데이터 (3개 컬럼)

```
| id        | document                        | label |
|----------|---------------------------------|-------|
| 9976970  | 아 더빙.. 진짜 짜증나네요 목소리 | 0     |
```

특성 엔지니어링 후 (9개 컬럼)

```
| id        | document           | label | predicted_label | confidence | is_correct
| review_length | length_category | sentiment_text |
|----------|-------------------|-------|-----------------|------------|-----------
-|---------------|-----------------|---------------|
| 9976970  | 아 더빙.. 진짜... | 0     | 0               | 0.9523     | True
| 18            | 짧은            | 부정          |
```

추가된 6개 컬럼

컬럼명	설명	생성 방법
`predicted_label`	모델 예측 (0=부정, 1=긍정)	HuggingFace Pipeline 추론 결과
`confidence`	모델 신뢰도 (0.0~1.0)	Pipeline 결과의 score 값
`is_correct`	예측 일치 여부 (True/False)	`label == predicted_label`
`review_length`	리뷰 글자 수	`len(document)`
`length_category`	길이 범주	~20자: 짧은, 21~50자: 보통, 51자~: 긴
`sentiment_text`	감성 텍스트	predicted_label을 "긍정"/"부정"으로 변환

---

5. 데이터 로딩 흐름

따릉이 대시보드와 동일한 **3단계 폴백** 패턴을 사용합니다.

```
1순위: 로컬 CSV (data/nsmc_analyzed.csv) — 이전에 분석한 결과
  ↓ 파일 없음
2순위: HuggingFace datasets("nsmc") 다운로드 → 2,000건 샘플링 → 감성 분석 → 로컬 저장
  ↓ 실패
3순위: 시뮬레이션 데이터 생성
```

> 첫 실행 시 2순위가 동작하여 모델 다운로드(~500MB) + 추론(~2분)이 진행됩니다. 이후에는 1순위(로컬 CSV)에서 즉시 로드됩니다.

---

6. 대시보드 페이지별 구성

6-1. 홈 페이지 (1_home.py)

KPI 카드 4개: 총 리뷰 수, 긍정 비율, 모델 정확도, 평균 신뢰도

차트:

- 감성 분포 도넛 차트 (긍정/부정 비율)
- 리뷰 길이별 감성 분포 히스토그램

- 긍정 키워드 TOP 10 / 부정 키워드 TOP 10

사이드바 필터: 감성, 신뢰도 범위, 리뷰 길이 범주

6-2. 모델 성능 분석 (2_analysis.py)

탭 1 — 성능 평가:

- 혼동행렬 히트맵 (실제 vs 예측)
- 정확도, 정밀도, 재현율, F1-Score 메트릭
- 혼동행렬 해석 안내 (TP, TN, FP, FN)

> 정확도 - 전체 리뷰 중, 모델이 긍정/부정을 올바르게 맞춘 비율

> 정밀도 - 모델이 '긍정'이라고 예측한 리뷰 중, 실제로도 긍정이었던 비율

> 재현율 - 실제 긍정 리뷰 중, 모델이 긍정이라고 맞춘 비율

탭 2 — 신뢰도 분석:

- 신뢰도 분포 히스토그램 (정답/오답별 색상)
- 정답 vs 오답의 평균 신뢰도 비교
- 신뢰도 구간별 정확도 바 차트 (캘리브레이션)

탭 3 — 오분류 사례:

- 모델이 틀린 리뷰 목록 (행 선택 가능)
- 오분류 유형 필터 (부정→긍정, 긍정→부정)
- 선택한 리뷰의 상세 정보

6-3. 데이터 조회 (3_data.py)

탭 1 — 특성 엔지니어링 결과:

- 9개 컬럼 전체를 조회할 수 있는 데이터프레임
- 신뢰도에 ProgressColumn, 정답여부에 CheckboxColumn 적용
- 감성/정답여부/신뢰도 필터 + CSV 다운로드
- 특성 엔지니어링 설명 expander

탭 2 — 원본 데이터:

- 컬럼 선택, 텍스트 검색, 감성 필터
- CSV 다운로드

---

7. 토론 포인트

인사이트 1: 특성 엔지니어링의 가치

> "원본 3개 컬럼에서 시작했는데, AI 모델의 예측 결과와 메타데이터를 추가하니 9개 컬럼이 되었습니다. 이것이 데이터의 분석 가치를 높이는 **특성 엔지니어링**입니다."

인사이트 2: 모델 신뢰도와 정확도

> "신뢰도가 95% 이상인 리뷰는 거의 틀리지 않지만, 60~70%대 신뢰도의 리뷰는 실제로 많이 틀립니다. 실무에서는 이 임계값을 기준으로 '자동 처리'와 '수동 검토'를 나눌 수 있습니다."

인사이트 3: 오분류 패턴

> "모델이 틀리는 리뷰를 직접 읽어보세요. '그냥 그랬어요', '아 진짜...' 같은 모호한 표현, 반어법, 단순 줄거리 나열 등에서 모델이 어려워합니다."

인사이트 4: 리뷰 길이와 감성

> "부정 리뷰가 긍정 리뷰보다 평균적으로 더 긴 경향이 있나요? 불만이 있을 때 사람들이 더 길게 쓰는 심리적 패턴을 데이터에서 확인해보세요."

---

8. 실행 방법

사전 준비

```
# 필요 패키지 설치 (아직 안 되어있다면)
pip install datasets scikit-learn
```

모델 미리 다운로드 (권장)

첫 실행 시 감성 분석 모델(~420MB)을 다운로드하느라 시간이 걸립니다. **수업 전에** 아래 명령어를 실행하여 모델을 미리 다운로드해두세요.

```
python -c "from transformers import pipeline; pipeline('sentiment-analysis',
model='WhitePeak/bert-base-cased-Korean-sentiment'); print('모델 다운로드 완료!')"
```

> 다운로드된 모델은 `~/.cache/huggingface/` 폴더에 캐시되어, 이후에는 자동으로 캐시에서 로드됩니다.

실행

```
cd BigDataAnalysis/5_week/movie_dashboard
streamlit run app.py
```

> 첫 실행 시 모델 다운로드(~500MB)와 2,000건 감성 분석(~2분)이 진행됩니다. 이후에는 로컬 캐시에서 즉시 로드됩니다.

데이터 재분석 (캐시 초기화)

```
# data/ 폴더의 캐시 파일을 삭제하면 다음 실행 시 재분석됩니다.
del data\nsmc_analyzed.csv
```